1. 문제 정의

경마에는 여러 승식 종류가 존재하며 그 중 3등 이내의 말을 순서와 상관없이 맞추는 삼복승식을 분류하기가 더 용이하여 선택하였다.

우리가 해결하고자 하는 문제의 경우, 다양한 종류의 특성들을 고려해야하고, 각각 특성들이 다양한 분포의 값들을 가지는 경우이기에 비선형적인 문제를 분류할 수 있는 모델들이 적합하다고 판단하였다.

이에 따라 이진 분류 문제로 정의하여 순위를 기준으로 3등 이내면 1로 나머지는 0으로 라벨링을 하였다. 분류 모델들 중 SVM을 사용한 이유는 선형적으로 분류가 안되는 문제를 커널트릭을 통하여 분류를 하는등 다양한 데이터 셋의 형태에 맞춤으로 커널트릭을 사용할 수 있고 소프트마진을 통해 일반화 성능을 올릴 수 있다는 강점을 활용하고자 하였다.

2. 데이터 수집

데이터의 신뢰성과 수집의 용이성을 고려해 한국마사회에서 2024년 5월부터 1년 6개월 치의 서울 경마데이터를 수집하였다.

경주성적표에 포함된 순위, 마번, 마명, 날씨, 습도, 구간별 성적 등을 크롤링하였다.

3. 데이터 전처리

데이터 셋의 형태가 훈련 과정에 큰 영향을 미치므로 전처리 과정이 가장 중요한 단계라고 판단하였고, 그렇기에 각 팀원이 서로 다른 방식으로 전처리를 수행하기로 했다. 실제로도 전처리를 어떻게 하느냐에 따라서 결과지표가 다르게 나온 것을 확인할 수 있었다.

우선 결측치를 파악했는데, 레이팅의 결측치비율은 28.9%로 높은 편이었고, 일부의 특성들이 10%부근, 나머지는 대부분 결측치가 없거나 적은 편이었다. 테이블에서 결측치가 있는 행들은 제거하거나, KNN을 사용하여 결측치를 처리하는 것을 고려하였다. 결측치가 높았던 레이팅의 경우는 아예 배제하는 것도 고려했다. 출전취소나 문제가 생겼던 말들의 데이터 역시 제외하였다.

그 다음, 각 특성들과 순위와의 연관관계를 따져보기 위해 통계학 기법인 카이제곱 독립성 검정을 사용해보고자 하였다. 독립성 검정 시행결과 습도, 주로상태, 날씨, 시작시간의 경우 P-Value(유의확률) 이 0.05 이상으로 해당 특성들과 순위는 독립관계라는 결과를 얻어낼 수 있었다. 따라서 해당 특성들을 제외하고 SVM을 돌려보는 것을 고려하였다.

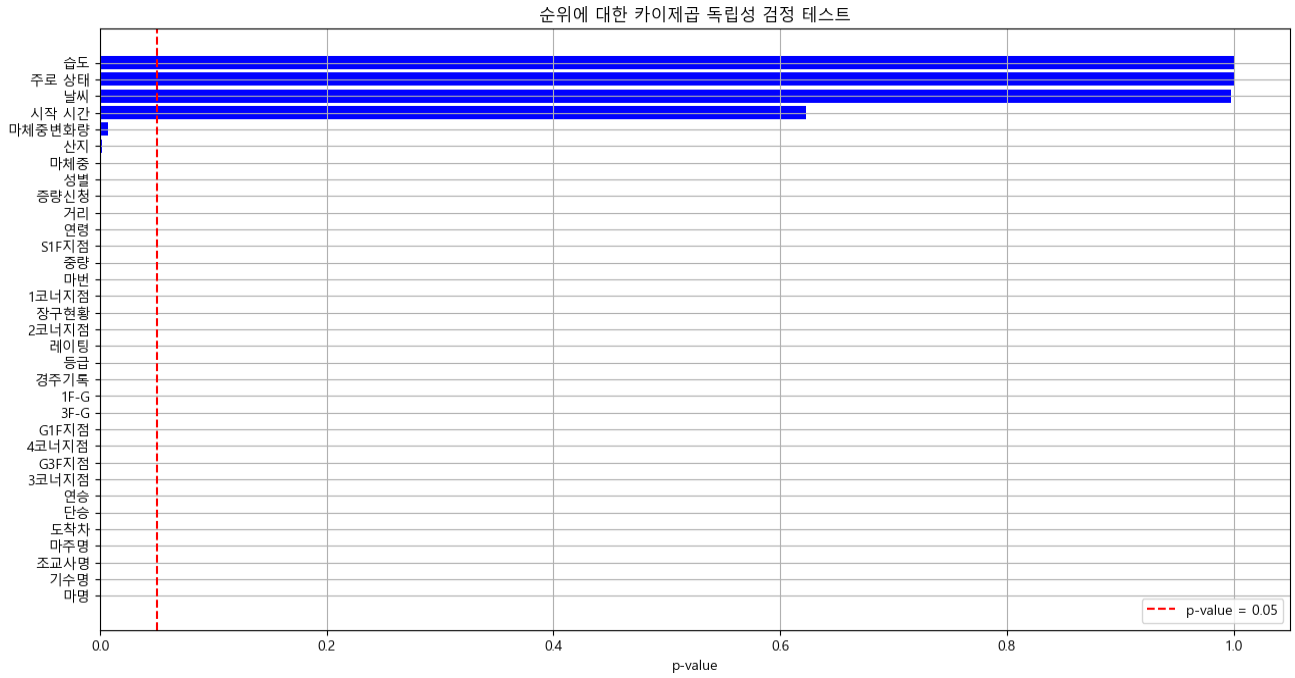

시간의 경우 초단위로 통일하여 환산, 불필요한 문자열을 제거, 분리할 수 있는 데이터는 분리하여 새로운 특성으로 만들어 사용하고자 하였다. 예를 들어 마체중에는 (-5)와 같이 마체중 변화량이 있었는데 따로 분리하여 새로운 특성으로 하였다. 특성 중 특이한 값을 가지는 경우는 도착차가 있었다. 도착차는 도착시의 이전 말과의 거리차이로, 목차, 코차, 머리차, 3/4마신, 1마신과 같은 특이한 단위를 사용했기에 m단위로 환산하고 그 다음 마신을 기준으로 통일하고자 하였다. 1등의 경우 제일 먼저 들어왔으므로 도착차를 전부 0으로 처리해두었다. 이후 각 특성들의 수치값들을 표준화하였다.

다른 한 명 팀원의 경우, 전처리를 수치형 데이터들을 전부 범주형 데이터로 변환하여 전처리를 수행했다. 그리고 결측치를 모두 Mean으로 처리한 후 그것들을 전부 원핫 인코딩했다. SVM으로는 결과를 내는데 시간이 너무 오래걸려 결과를 구할 수 없었고, 대신 Logistics로 돌려보았으나 F1-Score는 0.43으로 수치형 데이터를 사용하였을 시에 나온 F1-Score인 0.62보다 낮은 값이 나왔음을 확인할 수 있었다. 이러한 범주형 데이터를 전처리하는 방법에는 원핫 인코딩과 레이블 인코딩 방법이 있는데, SVM과 로지스틱스는 숫자의 차이가 결과에 영향을 주므로 레이블 인코딩은 쓸 수 없기에, 원핫 인코딩을 해야 한다.

원핫 인코딩을 사용할 시 각각을 One-Hot 벡터로 변환함에 따라 테이블의 Column의 개수가 엄청나게 늘어나 버리는 문제가 발생한다. 따라서 차원의 저주와 연관된 문제가 있을 것으로 추정했다. 원핫 인코딩에 따라 Column 개수가 엄청나게 늘어나 Feature Vector의 차원이 엄청나게 늘어나버리고, 데이터의 밀도가 급격히 감소하여 연산비용증가, 과적합 문제 등이 생긴 것으로 보인다. 특히 마명의 경우, 유니크한 마명의 개수가 2137개였는데 마명이 가장 큰 원인으로 판단하였다.

또한 수치형 데이터들을 범주형데이터로 만들기 위해선 분류가 필요하기에 분류 기준을 잘못잡는등 분류를 잘못하였을 가능성이 높다. 분류를 KNN이나 Clustering으로 하였다면, KNN이나 Clustering의 방식이 잘못되었을 것으로 예상된다.

4. 경마에 대한 도메인 지식 확보

팀원 모두 경마에 대한 도메인 지식이 부족했기에, 이에 대한 정보를 찾아보고자 하였다. 찾은 내용은 다음과 같다.

- 경주마는 2살 여름부터 경주로를 달릴수 있고, 3살 때 가장많은 성장을 하며, 4~5살에 전성기, 그 이후로는 하락세를 맞이한다는 정보를 확인하였다.
- 경주마의 경우 다양한 주행습성을 가지는데 초반에 달려나가서 선두에 서야만 기분좋게 말리는 말이 있는 가 하면, 초반에는 천천히, 비축한 힘으로 후반에 역전하는 것을 좋아하는 말이 있다는 것도 확인할 수 있었다.
- 부담중량의 경우 경주마가 등에 지고 달려야하는 무게로 기수의 체중, 안장, 채찍 등의 장구류들을 합한 것이 부담중량이다. 부담중량은 일종의 핸디캡으로써 연령, 성별, 유전적 특징 등에 의해 나타나는 각 경주마의 능력 차이를 인위적으로 조정하기 위해 부여하는 경주마가 짊어지고 뛰게 되는 무게라는 것을 알아낼 수 있었다.
- 착차의 경우 다음과 같은 사례가 있었다. – 경주마 두마리가 치열한 우승 다툼을 벌이는데 한마리가 약간 뒤쳐지게 되자 타고 있던 기수가 결승선 직전에 경주마의 목을 세게 밀었다. 그러자 말의 코가 앞으로 쭉 내밀어졌고, 이를 사진으로 판정한 결과 몸은 뒤쳐져 있지만 코가 먼저 내밀어져서 결승선에 닿은 것으로 드러나 해당 말이 우승했다.

우선 이러한 정보들을 통해 구간별 경주기록들, 연령, 중량, 착차, 성별, 산지, 장구류와 같은 요소들이 카이제곱 검정이라는 통계적 기법외에도 유의미한 요소로써 작용함을 도메인 지식을 통해 확인할 수 있었다. 연령의 경우 위의 정보를 기반으로 가중치를 부여하는 방법에 대해서 고려해보았다.

5. 머신러닝 적용

결과를 해석하기 위해서 평가지표들에 대한 이해가 필요하였다. 우리가 다루는 문제는 3등 이내냐, 아니냐를 기준으로 분류를 하는것이기에 Accuracy라는 지표만으로 모델을 평가하기에는 부적합하다고 판단하였다. 그 근거는 3등이내인 데이터의 수와 그렇지 않은 데이터의 수의 차이가 매우 크고, 클래스 불균형 문제가 있다고 판단하였기 때문이다. 이 경우 3등 이내의 말에 대해 맞추는 정확도가 낮아도, 그렇지 않은 경우를 맞추는 정확도가 높기에 모델을 잘못 평가할 것이라 생각하였다.

실제로 라벨링을 2등 이내, 1등 이내를 기준으로 잡고 SVM을 돌릴 시 Accuracy가 오히려 높아지고 F1 Score는 더 낮아지는 결과가 나오는 것을 확인할 수 있었다. 따라서 이러한 클래스 불균형 문제에 대해 Recall과 Precision의 조화평균인 F1 Score를 주요 평가지표로 사용하는 것이 적절하다고 판단하였다. SVM은 선형, 가우시안 커널에 대해서 각각 적용해보았다.

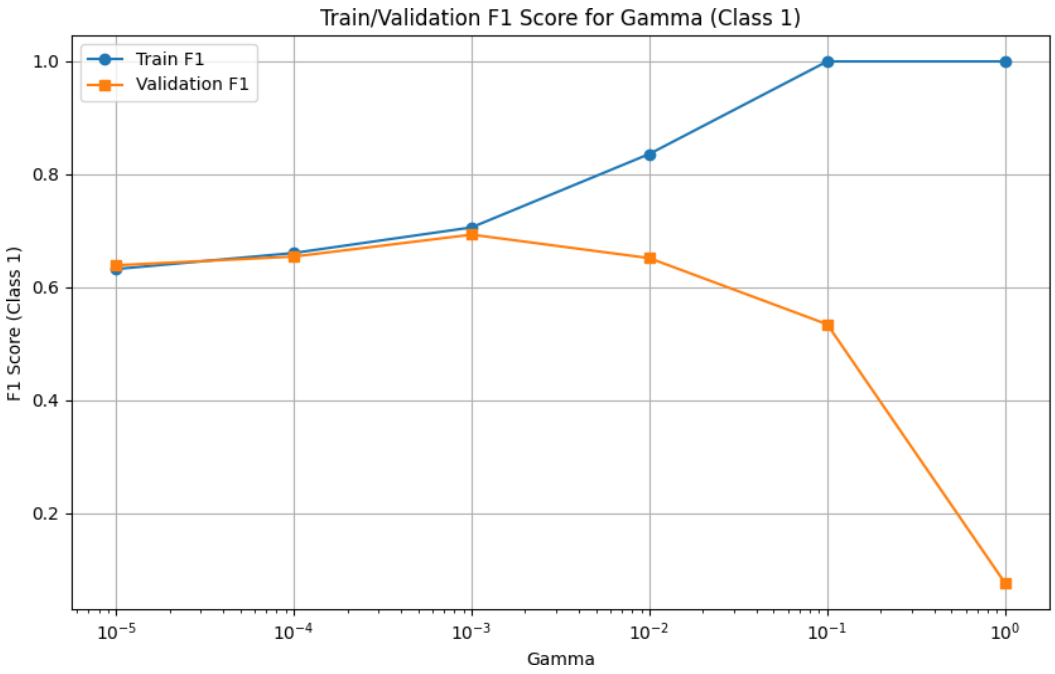

Grid Search를 통한 하이퍼 파라미터 C값과 Gamma값 찾기

Gamma 값이 0.001로 낮게 설정되었을 때 Validation Set에 대해 가장 높은 F1-Score를 얻었다는 것은, 모델이 더 넓은 범위의 데이터 포인트들을 포괄하는 부드러운 결정 경계를 사용함으로써 일반화 성능이 향상되었다고 볼 수 있었다. 그러나 그것보다 더 낮아질 경우 오히려 F1 Score가 낮아졌는데, 이는 Underfitting이 시작되었다고 판단해볼 수 있다.

C값이 100인 경우 가장 F1 Score가 높게 나왔으며, 이보다 클 시 Overfitting, 낮을 시 Underfitting으로 추정된다.

카이제곱 독립성 검정을 통해 순위와의 연관성이 독립이라 판단한 특성들을 제거해보며 SVM을 돌려보니 F1-Score가 오히려 더 낮아지는 경우가 생겼는데, 이에 대한 이유는 카이제곱 독립성 검정만으로 연관성이 독립이라 단정짓기에는 근거가 부족하며, 다른 통계학적 기법들을 사용해 다른 방식으로도 접근할 필요가 있다.

또한 카이제곱 검정은 Filter Methods의 일종으로 계산효율성이 높고 빠르지만, 특성과 목표변수의 관계만을 고려하여 특성 간의 상호작용을 반영하지 못한다는 단점이 있었는데 이런 부분도 요인으로 작용한 것으로 판단해 볼 수 있었다.

SVM과 로지스틱스 비교

SVM은 계산 시간은 오래걸리나 커널트릭 사용시 더 좋은 결과값을 얻어낼 수 있었고, 로지스틱스는 계산 시간이 매우 빠른 대신, SVM보다 상대적으로 낮은 결과값을 얻어냈다. 각각 Class 1에 대한 F1-Score는 0.62, 0.69 였다.

SVM을 선형으로 설정 하였을 시, 가우시안 커널보다 연산시간이 더 오래걸렸고 F1-Score역시 0.53으로 더 낮은 결과를 얻게 되었다. 이를 통해 데이터들의 분포가 비선형적이란 점을 결과를 통해서도 확인할 수 있었다.

로지스틱스는 하이퍼파라미터들을 완전탐색으로 찾아도 될 정도로 빠르다는 것을 알 수 있었다. 반면 SVM은 완전탐색으로 하이퍼파라미터 탐색 시 연산시간이 너무 오래걸려 완전탐색은 못하였고, Grid Search만 적용해보았다.

SVM의 경우 하이퍼 파라미터 튜닝을 더 세밀하게 수행한다면 더 높은 평가지표를 얻을 수 있을 것으로 보인다.

마명의 경우 그대로 원핫인코딩을 수행할 시 차원의 저주 문제가 발생하여 해당 특성들을 제외하고 SVM을 구하였었다. 이를 해결하기 위해선 말들에 대한 도메인지식들을 더 수집하고 공부하여, 마명을 기반으로 유의미한 지표값들을 얻어내는 것이 중요할 것이라 판단된다. 또한 PCA 주성분과 같은 기법들도 추가로 공부하여 차원축소를 하는 방법도 고려해볼 수 있다.